附录 A 术语表

> 用法：遇到不熟的词先在这里查一句话解释，再回对应章节看上下文。这里的定义刻意简略，不追求学术严格性。

A.1 模型与任务

术语	一句话解释	章节
模型（Model）	一组从数据里学出来的参数，给定输入产生输出	1
参数 / 权重	模型内部可调的数字，训练就是调它们	2、3
推理（Inference）	用训练好的模型算一次结果，不改参数	3、4
训练（Training）	用数据反复调整参数，让输出更接近期望	3
LLM（大语言模型）	以文本为输入输出、参数量很大的模型	1、4
多模态（Multimodal）	能处理两种以上输入或输出形式（如文字+图片）	10
ASR（语音识别）	音频 → 文本	10
TTS（语音合成）	文本 → 音频	10
目标检测（Object Detection）	图片 → 框 + 类别	10
分割（Segmentation）	图片 → 每个像素属于什么	10
Embedding（嵌入）	把文字/图片变成一串数字向量，便于比较相似度	2、10
分类 / 回归	输出离散类别 / 输出连续数值	3
聚类	没有标签，把相似的数据分到一起	3

A.2 数学与训练

术语	一句话解释	章节
向量 / Tensor	一串数 / 多维数组，是模型运算的基本单位	2
梯度下降	沿着"让误差变小"的方向一小步一小步调整参数	2
学习率	每步走多大；太大越过最优，太小走不动	2
损失（Loss）	衡量输出与期望差多少的数字	2
反向传播（BP）	从误差倒着算出每个参数该往哪调	2、3
激活函数	给网络加入非线性，否则多层等于一层	3
卷积（Convolution）	用小窗口在图上滑动提取局部特征	3
过拟合 / 欠拟合	训练集太好、新数据很差 / 两边都差	2、3
超参数	训练前人为设定的值（学习率、层数等）	2
迭代 / Epoch	更新一次参数 / 把训练集完整过一遍	2、3
有监督 / 无监督 / 半监督	有标签 / 无标签 / 少量标签	3
强化学习（RL）	通过奖励与试错学习策略	3
CNN / RNN / LSTM	卷积网络 / 循环网络 / 带门控的循环网络	3
Transformer	以注意力为核心的网络结构，现代 LLM 的基础	4
注意力（Attention）	计算每个词该"看"其他哪些词、看多重	4
位置编码	告诉模型词的先后顺序	4
预训练 / SFT / RLHF	大规模学语言 / 学按指令回答 / 按人类偏好调整	4
LoRA	只训练一小部分附加参数的低成本微调方法	10
量化（Quantization）	用更少的位数存参数，换更小的体积和更快的速度	10
蒸馏（Distillation）	用大模型的输出教小模型	10

A.3 使用与产品

术语	一句话解释	章节
Token	模型处理文本的最小单位，约等于一个词或半个词	4
上下文窗口	模型一次能"看到"的 token 总量上限	4、9
Temperature	控制输出随机性；低更稳，高更多样也更易跑偏	4
Top-p	只在概率最高的一部分候选里采样	4
系统提示 / System Prompt	在对话最前面设定角色与规则的文字	5、7
API	程序调用服务的接口，按用量计费	6
API Key	调用凭证，等同密码，泄露即被盗用	6
订阅	按月付费使用聊天产品，通常不含 API 额度	6
中转站	第三方转售 API 的服务，便宜但存在隐私与稳定性风险	6
本地部署	把模型跑在自己的机器上，数据不出本地	6、10
GGUF	一种常见的本地模型文件格式	10
显存（VRAM）	显卡上的内存，决定能跑多大的模型	10
Benchmark	标准测试集上的分数，只说明部分能力	10
Hugging Face	模型与数据集的公共托管平台	6、10

A.4 Agent 与工程

术语	一句话解释	章节
Agent（智能体）	能调用工具、多轮执行直到完成目标的模型程序	5
工具调用（Tool / Function Calling）	模型输出结构化请求，由程序真正执行	5
循环（Loop）	观察 → 决策 → 行动 → 再观察，Agent 的基本形态	5
MCP	让 Agent 以统一方式接入外部工具与数据的协议	5

术语	一句话解释	章节
SKILL	打包好的可复用操作说明与脚本，按需加载	5
Harness（脚手架）	围绕模型的一整套工程约束：指令、权限、测试、日志	5
上下文污染	无关或错误的信息进入上下文，带偏后续输出	9
交接摘要	换新会话时给下一轮的状态说明	9
RAG（检索增强生成）	先检索资料，再让模型基于资料回答	9
子代理（Subagent）	由主 Agent 派出的独立执行单元，有独立上下文	9
幻觉（Hallucination）	输出流畅但与事实不符	4、8
知识过时	模型训练数据早于当前事实	8
不遵守（Instruction Following 失败）	明知要求却没照做	8
Eval（评测）	用固定题目与标准衡量输出质量	8
VibeCoding	以自然语言驱动 Agent 完成开发的实践方式	11
回滚（Rollback）	把代码或数据恢复到之前的版本	9、13
限位 / 急停	硬件运动范围的硬性约束与立即停止手段	12

A.5 硬件与部署

术语	一句话解释	章节
GPU	图形处理器，因并行能力强而成为训练主力	3
CUDA	英伟达的 GPU 计算平台，很多框架默认依赖它	3
NPU	神经网络加速单元，常见于手机与单板机	3
边缘计算	在设备本地算，不把数据传回云端	3、12
集群 / NVLink	多卡多机协同训练 / 卡间高速互联	3
串口（UART）	逐位传输的简单有线通信，常用于控制板	12

术语	一句话解释	章节
MJPEG	把每帧压成 JPEG 连续传输的视频流格式	12
光流（Optical Flow）	通过像素移动估计物体运动	12
单应矩阵	描述两个平面之间投影关系的矩阵，用于图像拼接	12
逆运动学（IK）	由末端目标位置反算各关节角度	12